TT 模式下 GEMM 两种实现方法的对比

1. 概述

TT 模式的计算表达式为：

$$C += A^T \times B^T$$

其中矩阵A^T和B^T为列主序存储，存放原始数据和计算结果的矩阵C为行主序存储。为了将问题转化为 NN 模式的 GEMM，要么在计算前对输入矩阵A^T, B^T进行转置，要么在计算后对结果矩阵C进行转置。这里选择后者，一是因为只需要转置一个矩阵，二是因为在片上缓存中转置C能够与C的三缓冲策略相结合，从而无需占用额外的片上缓存。

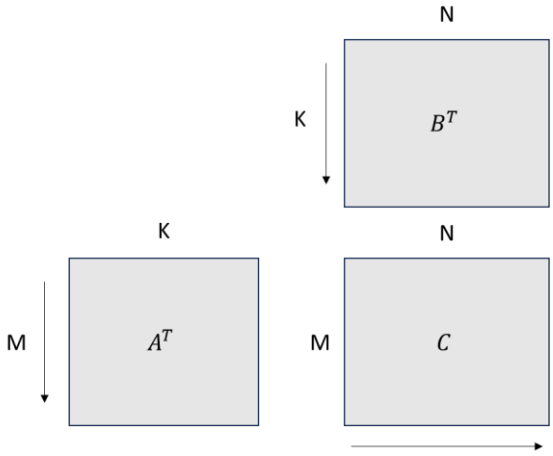

TT 模式下输入矩阵A^T, B^T都是列主序存储，因此二者在计算中的定位与 NN 模式中正好相反。这体现在，B 分块存储在 SM 中，而 A 的分块存储在 AM 中。片上缓存的分配如下图所视。

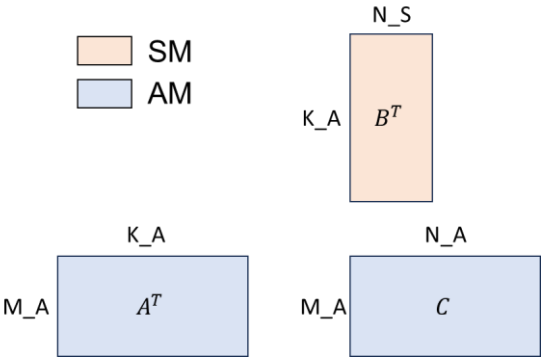

其中的分块参数取值分别是：

$$K_A = 512$$
$$M_A = 64$$
$$N_G = 576$$
$$N_A = 144$$
$$N_S = 6$$

与之相匹配的循环顺序则是：

```
for m_i = 0:M_A:M

    DMA_load(A[M_AxK_A]);

    for n_i = 0:N_A:N_G

        DMA_load(C[M_AxN_A]);

        for n_s = 0:N_S:N_A

            DMA_load(B[K_AxN_S]);

            micro_kernel();

        end n_s

        DMA_store(C[M_AxN_A]);

    end n_i

end m_i
```

其中微内核的算法与 NN 模式相同，但 A 和 B 角色互换，示意图如下：

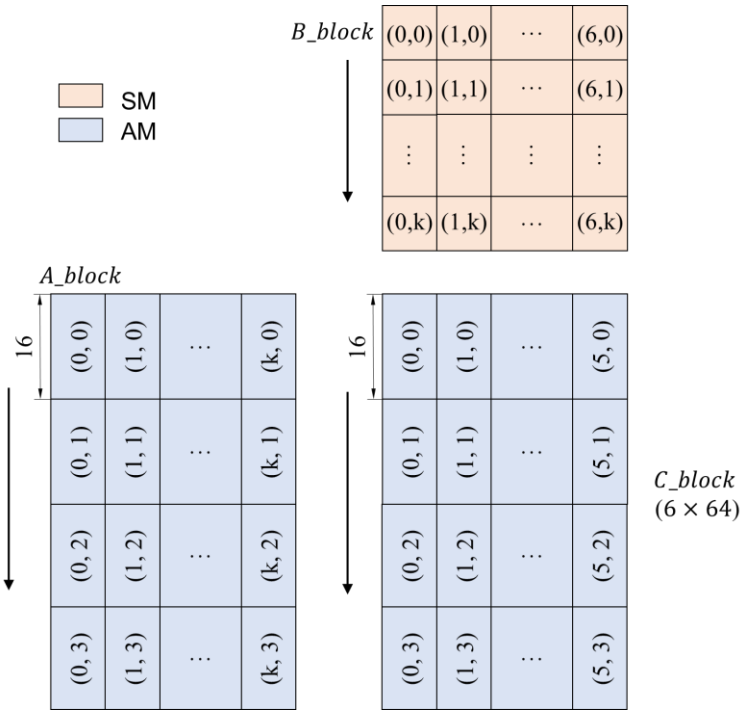

2. 方法

对计算结果C进行转置操作也分为两种方法。一种是 GEMM 算子和转置算子完全分离，GEMM 先对$A^T \times B^T$进行计算，结果存入 ddr，再调用转置算子将C从 ddr 取到片上缓存，执行转置操作后再写回 ddr。另一种方法是将转置操作融合进 GEMM 算子，每当微内核计算完毕，就对暂存在 AM 中的计算结果进行转置，然后将转置的结果与C的原始数据相加，再写回 ddr。这里只细说第二种方法，算法的伪代码如下。

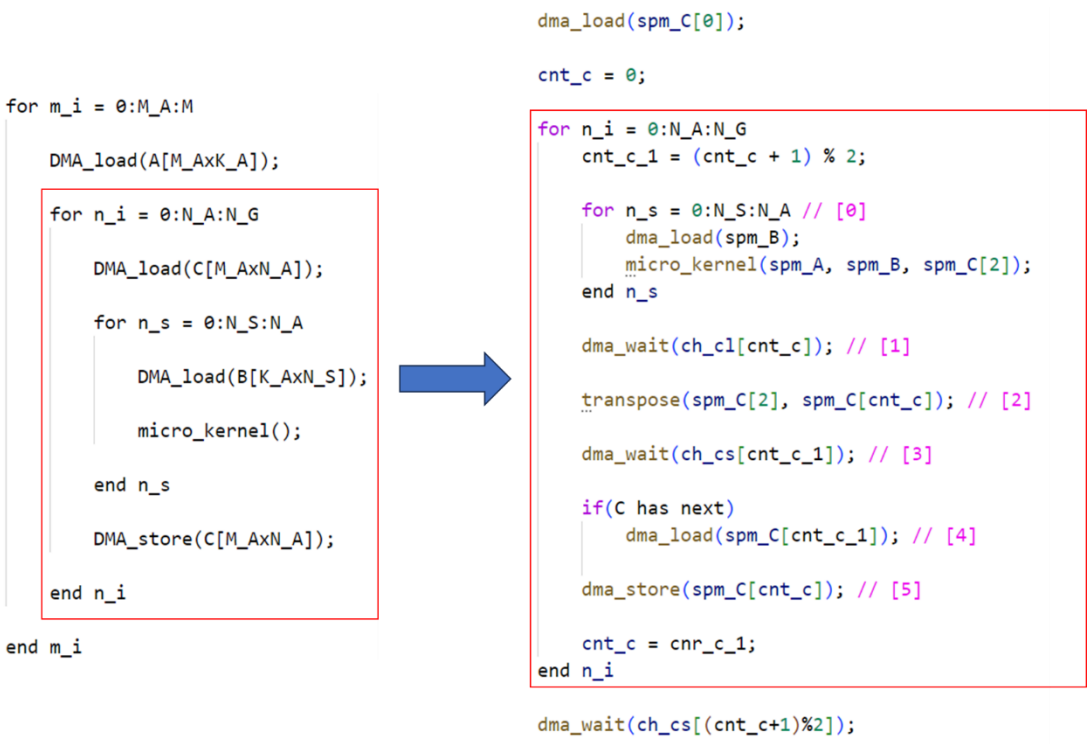

因为转置的对象是 C 分块暂存在 AM 中的数据，而 C 分块的读入和写回都发生在红框中的这层循环，所以主要对这层循环中的操作顺序进行修改。右图中编号[0-5]对应的分别是：

[0]内层循环(从 gsm 读入 B 分块+微内核执行)；

[1]等待当前 C 分块的原始数据写入 AM；

[2]对微内核的计算结果做转置，并与当前 C 分块的原始数据相加；

[3]等待上一个 C 分块写回 ddr 完成；

[4]加载下一个 C 分块的原始数据；

[5]写回当前 C 分块的数据。

与修改前相比，算法的一个不同在于，将计算结果与 C 分块的原始数据相加发生在转置函数[2]中，因此微内核不会用到 C 分块的原始数据，也就可以在原始数据完成写入[1]之前率先执行。微内核的计算结果会写入一个单独的缓冲区 spm_C2，待 C 分块的原始数据读入 AM 完毕[1]，即可执行转置操作[2]，将 spm_C2 中的数据转置后与 C 分块的原始数据相加。此外，[3]之所以放在[4]之前是因为上一个 C 分块与下一个 C 分块使用同一个缓冲区，必须等待旧数据写回完成才能开始装入新数据。[5]是将[2]的结果写回 ddr，这一操作也可以放在[3,4]之前。

算法的时空图如下，其中 spm_C0/1/2 分别是 C 分块占用的三个缓冲区。无转置的情况下，三个缓冲区地位相同，同一时刻分别在执行读入、计算和写回，交替往复。加入转置操作以后，spm_C2 缓冲区专供微内核写入计算结果，而 spm_C0/1 则交替地执行原始数据的读入、转置和写回。图中的箭头表示微内核的计算结果暂存到 spm_C2 之后，会经过转置和累加，得到最终结果写入 spm_C0/1。

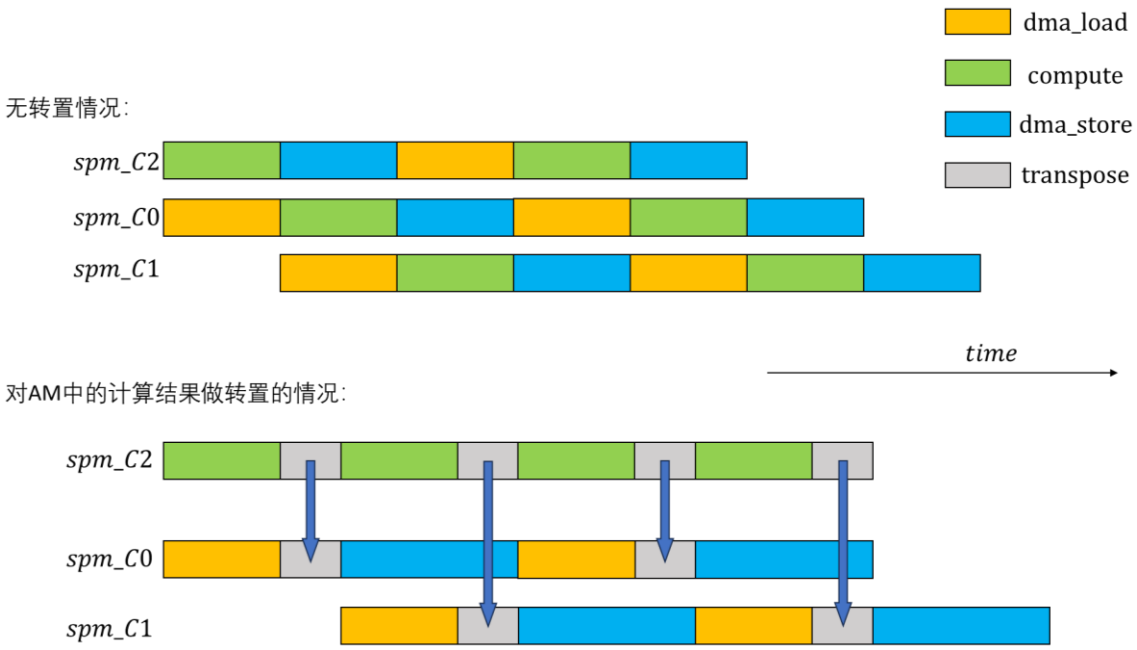

3. 性能测试

设输入矩阵的大小是 M=1536,K=2048,N=2304。对 TT 模式的两种实现方法(GEMM 与转置分离，GEMM 与转置融合)进行性能测试，结果如下。可以看出融合了转置的 GEMM(绿色)相比于不做转置的 GEMM(灰色)性能下降很小，只有不到 2%，且扩展性很好，随着计算核数的增加，平均单核性能没有显著的降低。反观计算与转置分离的 GEMM(蓝色)，单核执行的性能与融合算法相近(若矩阵规模减小则性能不如融合算法)，但随着计算核数的增加，平均单核性能下降明显，这是因为转置算子是访存受限的，性能无法随计算核数的增加而提高。